

课时3-统计

模块一：数据科学的核心逻辑

从直觉到算法的四层转化

数据科学并非凭空创造，而是对业务经验的数字化重构。一个完整的分析流程包含以下四个阶段：

- 直觉层 (Intuition)**：业务人员基于经验感知到的模糊规律。例如：“加大投放似乎能带来更高价值的用户”。
- 翻译层 (LLM Translation)**：利用大语言模型 (LLM) 将自然语言的直觉转化为计算机可执行的代码框架。
- 拟合层 (Small Model/Regression)**：利用经典统计学模型（如回归），处理具体数据，验证规律是否存在。
- 因果层 (Causality)**：利用因果推断算法，剥离干扰因素，确定“谁是因，谁是果”。

本课程阶段目标： 聚焦于第三层——构建回归模型，实现对历史数据的精准拟合。

模块二：概念解析——什么是“回归”？

将模糊的“关系”量化为精确的“权重”

在统计学中，**回归 (Regression)** 是一种通过分析变量之间关系，来估算结果的方法。在 LTV（用户终身价值）和 CAC（获客成本）的分析场景中，回归模型的作用相当于一个**“量化归因器”**。

- 直觉视角**：认为“渠道质量”、“折扣力度”、“用户年龄”都会影响 LTV，但影响程度未知。
- 回归视角**：将 LTV 视为结果变量 (Y)，将渠道、折扣、年龄视为特征变量 (X)。回归算法通过数学计算，赋予每个特征一个具体的**数值权重（系数）**。

示例公式解读：

代码块

```
1 LTV=(渠道权重×50)+(折扣权重×20)+基础值 LTV=(渠道权重×50)+(折扣权重×20)+基础值
```

回归的核心价值在于：它不再停留在“有关联”的定性判断，而是给出了“每增加一个单位投入，LTV 具体增加多少数值”的**定量结论**。

模块三：回归分析的三重境界

描述、预测与因果的层级递进

回归模型根据分析目的不同，可以发挥三种截然不同的作用。理解三者的区别是建模的关键：

1. 描述（Description）：对历史的数字化复盘

- **定义：**通过模型概括过去已经发生的数据规律。
- **关键词：**拟合（Fitting）。
- **含义：**如果模型生成的曲线能紧密贴合历史数据点，说明模型成功地“描述”了过去。这就像用尺子量出了历史数据的轨迹。
- **应用场景：**业务复盘，总结哪些因素在过去对 CAC 波动贡献最大。

2. 预测（Prediction）：对未来的概率性推演

- **定义：**基于历史拟合出的规律，对未知数据进行估算。
- **关键词：**外推。
- **含义：**假设未来的市场环境与过去相似，利用已建立的公式计算未来的 LTV。
- **前提：**只有当模型在历史数据上“拟合”得足够好，预测才具备基础的可信度。

3. 因果（Causality）：对机制的本质解释

- **定义：**确定变量变动是否是导致结果变动的**唯一真实原因**。
- **关键词：**控制变量。
- **区别：**回归能发现“公鸡打鸣”与“太阳升起”高度相关（拟合极佳），也能通过打鸣时间“预测”日出时间，但无法得出“打鸣导致日出”的因果结论。
- **注意：**因果推断需要更复杂的实验设计（如 A/B 测试），普通的回归模型主要用于发现相关性。

模块四：实战任务指引

建立解释 LTV 和 CAC 的回归模型

任务目标：

构建一个多元线性回归模型，输入渠道、成本、用户特征等变量，输出 LTV 或 CAC 的估算值。

验收标准：“能拟合就可以了”

在此阶段，不需要证明严格的因果关系（即不需要证明是广告费直接导致了 LTV 提升），也不需要极高的未来预测精度。

核心要求：

1. **特征显著性：**识别出哪些因素（X）与 LTV/CAC（Y）在统计上存在显著关联。

2. **拟合优度**：模型生成的预测值应尽可能接近历史真实值（残差最小化）。

总结：

当模型能够用数学公式准确“复述”出历史数据中 LTV 和 CAC 的变化轨迹时，即完成了从小模型拟合到预测的基础构建。