

课时4-预测分析

动议区

思想实验

假设某个爬虫软件通过某些关键词能把小红书的用户和帖子爬取出来。考虑哪些数据哪些关键词。

周会上讨论提出一个可行的公司觉得是一个销售的问题。放到课堂上去筛选要素。

课堂结论流转 to 周会上

建立一个关系，具备一定的预测能力

如何预测大数据专业的用户有多少

假设排商务去找到这些人，根据哪些特征去找

如果我们已经有了小红书数据，怎么预测哪些线索有更高的概率转化成客户？比如说有一些帖子提出了去问大数据专业怎么去学习呀，怎么去找工作呀，要不要去选这个专业等等，那么对于量潮课堂来说的话，我们有咨询服务，有实训服务，也那么也有一些课程的服务啊，他们有没有可能需要怎么从他们的一些话语包括评论啊，包括他们自己的评论啊，或者包括评论区的评论等等去，就假在假设我们这些数据都有的情况之下，从他帖子或者评论的出发，就哪些是更有可能去获得的，哪些可能会比较困难。

这个是商业数据分析的一个常见需求，就是通过历史数据、各种内外部公开，内部数据和外部公开数据去找到，可能去提高效率的方法，通常情况下，我们更关心它能不能准确地去预测，我们的行为是不是有效，因此对于预测的准确性非常的关注。

附议区

梁嘉伟

爬取卖课的高评论区帖子，分析哪些人的主页会对卖课感兴趣，如何排除掉水军账号的特征。从而可以进一步分析用户hua

查阅软件定制的售卖渠道和平台，分析哪些平台成交率高和获客成本比较低，以及客户扯皮度。分析这些软件售卖渠道的特点，进行针对性的获客投放。

朱彦真

（主要是对这方面不太懂，没有相关知识，可能写的东西比较偏

查阅有招投标信息的平台，根据业务和招投标的可能对象进行分析

实训生招聘

场景假设：公司急需招聘实训生，但猎头费用太高，想通过技术手段从开源社区和垂直论坛挖掘被动求职者。

卢一跃

评论区有求资料等行为的，主页粉丝较少点赞较少的反而可能是真实的普通人

主页账号完美，干货内容多风格相似，一天发n条笔记的账号可以排除

几乎同一时间的n个账户同时在评论区求资料等发言也可能是托

问题：哪些渠道适合大面积测试，哪些渠道只适合小范围测试？

窦烨

结合梁和卢的，还需要看看能否获得他们的关注列表、收藏列表（如果用户开放了权限的话）。

还有一个新想法是，可以爬取那些“xx岁转行来不来不及”、“xxx专业能学得会编程吗”、“不想干现在的工作了咋办”这种帖子下面评论区的用户相关信息，来分析潜在客户。

叶妍熹

问题：用户市集消费记录预估用户消费能力和价格弹性

周诗佳

（文科生不太懂，，）

小红书卖课爆款笔记哪些标题结构，封面风格，高频词云等使用情况有利于抓取强目的性（希望考证，实习etc）用户

爬取评论区高情绪强需求人群评论和回复（这类人求职等意向比较强烈，更有利于被说服转化为客户），分析他人哪些宣传沟通的回复能有效抓住这类用户，提高成功率

吴承远

简介里是否出现专业、学习、行业相关描述，专业相关话题标签等。

水军排除：

- 1.大量发布帖子消息，或者说发布时间稳定不间断
- 2.内容高度同质化
- 3.无个人真实生活痕迹
- 4.评论区大量出现推广回复评论
- 5.无真实互动行为（点赞收藏）

朴禹诚

我觉得可以做测试，然后给个report，既然是开放选题就可以通过逻辑，不要求固定格式产出，自己的产出要上的自己的要求

决议区

这份文档记录了一次关于“商业数据分析与潜在客户挖掘”的课堂/周会讨论纪要。核心议题是如何利用技术手段（爬虫、数据分析）从公开社交平台（主要是小红书）挖掘高价值销售线索。

以下是对动议区和附议区内容的分析整理，将其归纳为四个核心模块：项目目标与逻辑、目标用户画像构建、数据清洗与排噪、以及拓展场景与验证。

一、项目目标与核心逻辑

核心问题：如何从海量公开数据中，精准预测并筛选出高转化概率的潜在客户？

业务场景：针对“量潮课堂”的大数据专业相关服务（课程、咨询、实训），寻找有需求的用户。

分析逻辑：

数据源获取：通过关键词爬取小红书帖子及评论区。

特征提取：分析用户发言内容、主页特征、互动行为。

模型预测：建立特征与转化意愿之间的联系，指导销售行为。

二、目标用户画像构建（找谁？）

通过多维度的特征组合，识别出具有真实需求的潜在客户。

1. 基于内容的“显性需求”特征

求知型关键词：

询问专业前景：“大数据专业怎么学”、“就业方向”、“要不要选这个专业”。

求助型行为：评论区“求资料”、“求分享”、“求链接”。（卢一跃、梁嘉伟）

焦虑与转折型关键词（痛点）：

职业转型：“xx岁转行来得及吗”、“不想干现在的工作了”。

能力恐慌：“文科生能学会编程吗”、“零基础怎么入门”。（窦烨）

高意向情绪特征：

识别高情绪价值的评论，如表达强烈求职意向、对现状的不满、急迫的求知心态。（周诗佳）

2. 基于用户画像的“隐性特征”

身份标签：简介中出现“学生”、“大三”、“求职”、“大数据”、“程序员”等标签；关注的话题标签与行业相关。（吴承远）

消费能力预估：通过用户在市集的消费记录，预估其消费能力和价格敏感度，以此判断是否为高客单价产品的潜在客户。（叶妍熹）

竞品关注：关注卖课博主的帖子，尤其是高评论区下的活跃用户。（梁嘉伟）

3. 内容偏好分析（吸引法则）

分析爆款卖课笔记的标题结构、封面风格、高频词云，反向推导被吸引的用户是否具有强目的性（如考证、实习）。（周诗佳）

三、数据清洗与排噪策略（排除谁？）

为了提高预测准确性，必须剔除水军、营销号和无效账号。

1. 账号维度排噪（吴承远、卢一跃）

发布行为异常：发布时间过于规律（机器行为）、发布频率过高（一天N条）、内容高度同质化（搬运/营销号）。

主页缺失真实感：只有干货/广告，无个人生活痕迹（照片、心情等）。

完美人设排除：主页过于完美、粉丝少但点赞多（可能为刷量账号）。

2. 互动维度排噪（卢一跃、梁嘉伟）

群体行为：同一时间N个账户在评论区发相同求资料言论（典型的托/引流团队）。

无效互动：无真实点赞收藏行为，评论区充斥推广回复。

3. 深度数据验证（窦烨）

若权限开放，查看用户的“关注列表”和“收藏列表”，关注列表全是营销号的可信度降低，收藏真实学习资料的为高潜用户。

四、拓展场景与行动验证（怎么做？）

1. 拓展场景

B端/实训招聘：避开昂贵猎头，从开源社区、垂直论坛挖掘“被动求职者”；分析招投标平台信息锁定B端客户。（朱彦真）

渠道投放优化：分析不同软件定制售卖渠道的成交率、获客成本及“扯皮度”（售后难度），指导精准投放。（梁嘉伟）

2. 实施路径与验证

测试策略：区分渠道属性，大面积测试（低成本公域）与小范围测试（高成本私域）相结合。（卢一跃）

转化验证：爬取高转化帖子的评论区，分析那些成功的“宣传沟通回复”使用了什么话术，学习并复制有效沟通模式。（周诗佳）

产出导向：不拘泥于固定格式，通过逻辑测试产出Report，验证“行为有效性”和“预测准确性”。（朴禹诚）

五、总结：商业数据分析闭环

本次讨论构建了一个完整的商业分析闭环模型：

数据输入：关键词爬取（显性需求+焦虑痛点）。

数据清洗：排除水军、营销号（行为分析+内容鉴别）。

特征工程：结合消费能力、身份标签、竞品互动建立评分模型。

预测输出：筛选出高概率转化线索（如：有消费能力+真实求助+处于职业转折点）。

反馈优化：销售跟进后，将结果反哺模型，优化关键词和筛选逻辑。

核心价值：将模糊的“找客户”过程，转化为可量化、可预测的数据工程问题，从而降低获客成本，提高销售人效。

将这个案例转化为《定量分析》课程内容是一个非常棒的想法。目前的讨论多停留在定性描述（如“看起来像水军”），而定量分析的核心在于将定性假设转化为可量化指标、建立数学模型并进行统计检验。

以下是针对该课程内容设计的建议，分为四个教学模块，旨在引导学生从商业直觉走向数据实证。

模块一：变量操作化定义——从“直觉”到“数据”

教学目标：让学生学会如何将模糊的商业概念转化为可计算的具体数值指标。

内容建议：

针对附议区提出的各种特征，要求学生进行“指标化”定义。例如：

1. “水军/营销号”的量化定义：

- *原想法：* “内容高度同质化”、“一天发N条”。
- *定量指标：*
 - 发文频率变异系数：计算用户发文时间间隔的标准差/均值。真实用户通常波动大，机器人可能非常规律（变异系数接近0）。
 - 文本相似度：计算用户历史帖子内容的TF-IDF向量余弦相似度，设定阈值（如>0.8判定为搬运/营销）。
 - 互动比率异常度：点赞数/粉丝数（比率过高可能买粉），或评论数/点赞数（比率过高可能控评）。

2. “潜在客户意向”的量化定义：

- *原想法：* “焦虑”、“求助”、“求资料”。
- *定量指标：*
 - 情感极性得分：使用NLP工具对评论文本打分，负面情感得分高的用户可能更焦虑（如-0.5以下）。
 - 关键词权重向量：构建“求职词袋”、“转行词袋”，计算评论与词袋的匹配度。
 - 用户决策阶段指数：根据“了解-兴趣-欲望-行动”模型，对不同关键词赋权（如“怎么学”=0.3，“求推荐机构”=0.8）。

课堂练习：给定几组用户样本数据，让学生设计指标并计算，对比人工判断与指标计算的一致性。

模块二：描述性统计与数据探索（EDA）——发现规律

教学目标：掌握数据分布特征，识别异常值，进行初步筛选。

内容建议：

1. 分布分析：

- 分析用户粉丝数的分布。大部分真实咨询用户可能集中在“长尾”低粉丝区，而营销号可能呈现两极分化。
- 分析评论时间的分布。真实用户的评论时间是否符合“人类作息”（如深夜少，午休多）？

2. 相关性分析：

- 探究变量之间的线性关系。例如：帖子的“焦虑关键词密度”与“评论互动数”是否存在显著正相关？
- 绘制散点图矩阵，观察不同特征（如粉丝数、笔记数、注册时长）之间的关联。

课堂练习：使用Excel或Python对爬取的样本数据进行可视化，画出直方图和散点图，识别是否存在明显的“离群点”（可能是水军）。

模块三：预测建模——建立关系

教学目标：构建分类模型，预测转化概率，这是定量分析的核心。

内容建议：

将问题定义为一个**二分类问题**（是否为高价值线索）**或回归问题**（转化概率是多少）。

1. 特征工程：

- 将模块一设计的指标整合成特征向量 $X=[x_1, x_2, \dots, x_n]$ 。
- 处理缺失值（如有些用户不开放收藏夹）。

2. 模型选择与构建：

- 逻辑回归：最经典的定量分析方法。模型公式 $P=1/(1+e^{-(\beta_0+\beta_1x_1+\dots)})$ 。
- *教学重点：* 解释回归系数 β 的意义。例如，若“评论中出现‘求资料’”的系数为正且显著，说明这是正向预测因子；若“账号注册时长”系数不显著，说明该特征对预测无帮助。
- 决策树/随机森林：用于筛选哪些特征最重要。例如，模型可能会发现“评论情感得分”比“粉丝数”更能预测转化。

模块四：模型评估与商业决策——验证有效性

教学目标：理解准确率不是唯一指标，结合商业成本进行决策。

内容建议：

1. 混淆矩阵与评估指标：

- 准确率：预测对的占比。
- 召回率：错过了一个高价值客户（假阴性）代价多大？对于销售漏斗，通常希望召回率高，宁可错杀一千（销售人员多打几个电话），不可放过一个。
- 精确率：销售团队的时间成本。如果精确率太低，销售人员会因打太多无效电话而疲惫。

2. 成本收益分析：

- 计算 获客成本 (CAC) 与 客户终身价值 (LTV)。
- 设定阈值：模型预测概率高于多少分（如0.7分）才值得销售去跟进？这需要定量计算：收益=预测准确率×LTV-单次销售成本

3. A/B测试设计：

- 验证模型有效性。将线索随机分为两组：A组使用模型筛选的高分线索跟进，B组随机跟进。对比两周后的转化率差异，进行T检验，验证差异是否具有统计学显著性。

练习：计算在不同预测阈值下，销售团队的ROI（投资回报率），寻找最优的决策切点。

课堂任务

组队尝试完成模块三的二分类|回归问题的建模

